


Análisis Topológico de Datos + LSTM

Forecasting del PPI de Berries (FRED: WPUSI01102B)

Junio 2008 - Abril 2026 | 215 observaciones mensuales




Sesiones 2-10 | TDA · Takens Embedding · LSTM · EP Loss

Los Datos: PPI Mensual de Berries


Sesiones 2-3 | EDA y definición de subperiodos para análisis TDA

n = 215 obs | $\mu = 142$ | $\sigma = 45$ | min = 69 | max = 299




¿Qué es TDA y por qué funciona?

Sesiones 2-3 | Takens Embedding + Persistent Homology



Pipeline TDA → Features




TDA por Subperiodo: H₁ Persistence

Sesiones 2-3 | La crisis 2008-2012 muestra la estructura topológica más fuerte

Intensidad del Loop H₁
(proxy de estacionalidad)

Interpretación Topológica
por Subperiodo



2008-2012

H₁ más persistente → crisis
crea estructura topológica
más distinguible

2013-2019



H₁ más débil → estabilidad
reduce la complejidad
topológica

2020-2026

H₁ media → pandemia
recrea volatilidad pero
con patrón diferente

Optimización de Parámetros TDA


Sesión 4 | Grid search sobre W, D, τ — parámetros finales: W=36, D=6, τ =3



Parámetros finales adoptados en sesiones posteriores: W=36, D=6, τ =3 (ventana 3 años, embedding cubre 15 meses, span trimestral)

Sesiones 5-6: RandomForest → LSTM+TDA v1

Primer modelo end-to-end con TDA features | 152 features/paso de LSTM



LSTM+TDA v1 — Input / Output

X shape: (117, 12, 152)

- 117 secuencias (train)
- 12 pasos temporales
- 152 features/paso:
 - price(t): 1
 - PE H_0, H_1 : 2
 - AMP H_0, H_1 : 2
 - max H_1 : 1
 - BettiCurve(20): 20
 - Raw Takers (21×6): 126

ARQUITECTURA

LSTM(64, rs=True, drop=0.2)
→ LSTM(32, drop=0.2)
→ Dense(16, relu)
→ Dense(1)
Loss: MAE | Adam(1e-3)
EarlyStopping patience=20

OUTPUT


$\hat{y}$ = precio PPI mes siguiente
Test MAE: 29.49
Test R^2 : 0.569

LSTM Puro vs LSTM + TDA


Sesiones 7-8 | ¿Agrega valor real el TDA al LSTM?

Comparación de Arquitecturas


LSTM Puro



LSTM + TDA



MAE por Modelo




TDA aporta ~14% mejora sobre LSTM puro | Features topológicas capturan estructura cíclica no lineal del precio

TDA v2: Features Enriquecidos

Sesión 8 | De 152 a 157 features — homología H_0 , H_1 , H_2 + Wasserstein

TDA v1 — 152 features


TDA v2 — 157 features



★ Nuevos en v2: Wasserstein distance (cambio topológico entre ventanas) + H_2 (cavidades) + H_1 count | No exógenas: N=168 demasiado pequeño

Ablation Study — Todos los Modelos LSTM

Sesión 8 | ¿Qué componente aporta más valor?



Experimentos Avanzados: EP Loss + Calendar Features

Sesiones 9-10 | Penalización de peaks + features de estacionalidad explícita

Sesión 9 — EP Loss + Multi-Task Head

Enhanced Peak Loss:

$L_{EP} = \text{mean}[(1 + \alpha \cdot \text{is_peak}) \cdot |y - \hat{y}|]$
+ $\beta \cdot \text{BCE}(\text{peak_classification})$
 $\alpha \in \{2, 3, 5, 8\}$ $\beta \in \{0.1, 0.3, 0.5\}$ → 12 combos


Arquitectura dual:

Shared trunk → [price_out: linear]
→ [peak_out: sigmoid]
Ganador: $\alpha=5$, $\beta=0.5$

Resultado:

Test MAE = 31.33 (Baseline: 27.92)
→ EP Loss perjudicó globalidad
con N=168 pequeño


Sesión 10 — Calendar + Lag Features



Predicciones vs Real — Test Set

Comparación visual LSTM Puro vs LSTM+TDA v1 (Sesión 6)


Test Set: Conjunto de Prueba (últimas 26 observaciones)



Resumen y Conclusiones

MAE ranking completo — Hallazgos clave — Próximos pasos

Conclusiones Clave



✓ TDA agrega valor real

–14% MAE vs LSTM puro
Features topológicos capturan
estacionalidad no lineal

✓ v1 vs v2: similar MAE

Más features TDA no garantiza
mejora con N=168 muestras
Riesgo de sobreajuste

✓ Calendar features útiles

month_sin/cos → –1.63 MAE
LSTM no infería estacionalidad
anual desde TDA solo

✗ Variables exógenas

N=168 demasiado pequeño
Variables macro no ayudan
con tan pocos datos

→ Próximo paso

Entrenar en diferencias $\Delta price$
+ STL decomposition para
eliminar el shift implícito