

Análisis Topológico de Series de Tiempo: Índice de Precios al Productor de Berries



*Aplicación del embedding de Takens y homología persistente de Vietoris-Rips
para el pronóstico del PPI de berries (WPUSI01102B, Jun 2008–Abr 2026)*

Topología de Datos

14/Junio/2026

Equipo 1

Nombre completo	Matrícula
Andrés Martínez Almazán	A01621042
Josué Tapia Hernández	A01621056
José Emilio Martínez Hernández	A01403100
Diego Arechiga Bonilla	A01621045

Instructor: Dr. Hugo García Tecocoatzi
Tecnológico de Monterrey, Campus Guadalajara

Índice

1. Introducción	2
1.1. Descripción del problema	2
1.2. Objetivo	2
1.3. Datos	2
2. Metodología	4
2.1. Análisis Topológico de Datos en series de tiempo	4
2.2. Pipeline con y sin TDA	5
2.2.1. Pipeline sin TDA	5
2.2.2. Pipeline con TDA	5
2.3. Modelos comparados	6
2.3.1. Random Forest (RF)	6
2.3.2. SARIMA	7
2.3.3. LSTM	7
2.3.4. Enhanced Peak Loss + Multi-Task (Sesión 9)	7
2.3.5. Características de Calendario y Lag (Sesión 10)	7
2.4. Validación	7
2.4.1. División para RF y SARIMA	8
2.4.2. División para LSTM (todas las variantes)	8
3. Resultados	8
3.1. Comparación global de métricas	8
3.2. Predicciones futuras	9
3.3. Visualizaciones	9
3.3.1. Comparación de predicciones en validación	10
3.3.2. Comparación gráfica de métricas	10
3.3.3. Diagramas de persistencia por subperiodo	11
3.3.4. Métricas comparativas (MAE, RMSE, R^2)	12
3.3.5. Calendario y lag — Sesión 10	13
3.3.6. Grid search EP Loss (Sesión 9)	13
4. Discusión	14
4.1. ¿Aportan las características TDA valor predictivo?	14
4.2. Rendimiento comparativo por clase de modelo	14
4.3. Técnicas avanzadas: EP Loss y características adicionales	15
4.4. Limitaciones	15
5. Conclusiones	16
5.1. Resumen de hallazgos	16
5.2. Trabajo futuro	16
Referencias	18

1 | Introducción

1.1 | Descripción del problema

Los precios de berries (arándanos, fresas, frambuesas y moras) exhiben una volatilidad pronunciada producida por la confluencia de tres factores: estacionalidad agrícola (ciclos de cosecha anuales), choques macroeconómicos (crisis financiera de 2008, pandemia de COVID-19, inflación post-pandemia) y perturbaciones climáticas que alteran la oferta de forma abrupta. Esta combinación genera una serie de tiempo con estructura cíclica fuerte pero no estacionaria, lo que dificulta el pronóstico con métodos convencionales.

El Análisis Topológico de Datos (TDA) ofrece una perspectiva complementaria: mediante el embedding de Takens, la serie univariada se reconstruye como una nube de puntos en un espacio de alta dimensión, y la homología persistente cuantifica los ciclos y componentes conexas de esa nube. Estas características topológicas son invariantes frente a deformaciones suaves de la señal y, por tanto, capturan patrones de largo plazo (estacionalidad, rupturas estructurales) que los descriptores estadísticos convencionales podrían omitir.

1.2 | Objetivo

El objetivo general es comparar el desempeño predictivo de modelos *sin* y *con* TDA para el pronóstico del índice PPI de berries a un horizonte de un mes hacia adelante. Los objetivos específicos son:

1. Caracterizar topológicamente tres subperiodos históricos (2008-2012, 2013-2019, 2020-2026) mediante diagramas de persistencia y entropía topológica.
2. Construir una familia de modelos de pronóstico que van desde un RF sin TDA hasta un LSTM con características topológicas enriquecidas y variables exógenas.
3. Cuantificar la ganancia marginal atribuible a TDA en cada clase de modelo.
4. Explorar técnicas avanzadas: función de pérdida Enhanced Peak (EP), cabeza multi-tarea de clasificación de extremos, y características de calendario y lag.

1.3 | Datos

La fuente de datos es el **FRED Producer Price Index for Berries**, identificado con el código **WPUSI01102B**. La serie mide el nivel general de precios que reciben los productores domésticos de berries, usando como base el año 1982 (índice base = 100). La Tabla 1 resume las principales características del dataset.

Cuadro 1. Características del dataset WPUSI01102B.

Atributo	Valor
Fuente	Federal Reserve Bank of St. Louis (FRED)
Código	WPUSI01102B
Frecuencia	Mensual
Periodo	Junio 2008 – Abril 2026
Observaciones	215
Columnas	observation_date, WPUSI01102B
Unidad	Índice PPI (base 1982 = 100)
Media	142.47
Desviación estándar	44.71
Mínimo	69.2 (Febrero 2020)
Máximo	299.4 (Enero 2021)
Valores faltantes	0

La serie presenta estacionalidad anual marcada, con picos en los meses de noviembre-diciembre (temporada de cosecha alta en Chile y México, principal fuente de importaciones invernales) y valles en los meses de verano en el hemisferio norte. El rango de variación es amplio: el índice ha oscilado entre 69.2 y 299.4 puntos, reflejando tanto la volatilidad estructural del mercado como los choques excepcionales de la pandemia de COVID-19.




Figura 1. Serie temporal del PPI de Berries (WPUSI01102B) con los tres subperiodos históricos sombreados. Rojo: crisis financiera 2008-2012. Verde: estabilidad 2013-2019. Azul: pandemia e inflación 2020-2026.

La Tabla 2 desglosa las estadísticas descriptivas por subperiodo histórico, definidos según los regímenes económicos identificados en el análisis exploratorio.

Cuadro 2. Estadísticas descriptivas por subperiodo histórico.

Subperiodo	Fechas	n	Media	Desv. Est.	Mín.	Máx.
Crisis financiera	Jun 2008 – Dic 2012	55	148.3	47.2	80.5	282.7
Estabilidad	Ene 2013 – Dic 2019	84	135.3	39.1	74.2	248.5
Pandemia/Inflación	Ene 2020 – Abr 2026	76	146.2	47.6	69.2	299.4
Total	Jun 2008 – Abr 2026	215	142.5	44.7	69.2	299.4

2 | Metodología

2.1 | Análisis Topológico de Datos en series de tiempo

El TDA aplicado a series de tiempo sigue el paradigma de reconstrucción de atractores propuesto por Takens (1981). A partir de una serie univariada $\{p_t\}$, se construye un embedding en $\mathbb{R}^d$ mediante el mapeo:

$$\Phi : p_t \mapsto (p_t, p_{t-\tau}, p_{t-2\tau}, \dots, p_{t-(d-1)\tau}) \quad (1)$$

donde d es la dimensión de embedding y τ es el retardo temporal. La nube de puntos resultante $\mathcal{E} \subset \mathbb{R}^d$ preserva las propiedades topológicas del atractor subyacente.

Sobre $\mathcal{E}$ se construye el complejo simplicial de Vietoris-Rips parametrizado por un radio ϵ , y se calcula su homología persistente: para cada dimensión k (H_0 = componentes conexas, H_1 = ciclos), se rastrean los pares de nacimiento/muerte (β^k, δ^k) a medida que ϵ crece desde 0 hasta ∞ . Los pares de larga vida $\delta^k - \beta^k \gg 0$ señalan estructura topológica robusta (no debida a ruido).

La Tabla 3 resume los parámetros utilizados en este trabajo. Para el análisis subperiódico (Sesiones 2-4) se empleó $d = 12$ (un año de datos mensuales) y $\tau = 3$ (trimestral). Para el pipeline de pronóstico (Sesiones 6-10) se utilizó una ventana deslizante de $W = 36$ meses con $d = 6$, $\tau = 3$, produciendo embeddings de 21 puntos por ventana.

Cuadro 3. Parámetros TDA utilizados.

Parámetro	Análisis subperiódico	Pronóstico (rolling)
Dimensión de embedding d	12	6
Retardo τ	3	3
Ventana W	Subperiodo completo	36 meses
Puntos por embedding	Variable	21
Dimensiones homológicas	H_0, H_1	H_0, H_1 (v2: $+H_2$)
Biblioteca	giotto-tda	giotto-tda

El análisis de homología persistente reveló diferencias topológicas significativas entre los tres subperiodos (Tabla 4).

Cuadro 4. Persistencia máxima en H_1 por subperiodo (embedding $d = 12$, $\tau = 3$).

Subperiodo	Pers. máx. H_1	Ciclos	Interpretación
2008-2012	130.13	5	Estructura cíclica muy fuerte; crisis + recuperación
2013-2019	22.35	28	Ciclos múltiples de baja amplitud; mercado estable
2020-2026	7.99	3	Ciclos cortos; pandemia rompe la estructura estacional

El subperiodo 2008-2012 exhibe la mayor persistencia en H_1 (130.13), lo que indica ciclos de gran amplitud asociados a la crisis financiera y la volatilidad post-crisis. En contraste, el periodo 2020-2026 presenta la menor persistencia (7.99), sugiriendo que los choques pandémicos fragmentaron la estructura cíclica de la serie.

2.2 | Pipeline con y sin TDA

2.2.1 Pipeline sin TDA

Los modelos sin características topológicas reciben directamente los valores históricos de precios (o sus rezagos estadísticos). Para RF y SARIMA, el input es la propia serie de precios sin transformación topológica. Para el LSTM puro, la entrada es una secuencia de 12 precios mensuales en escala normalizada con `StandardScaler`.

2.2.2 Pipeline con TDA

Para cada instante t en el horizonte de pronóstico, se extrae un vector de características topológicas a partir de la ventana $[p_{t-W+1}, \dots, p_t]$ ($W = 36$):

1. **Embedding de Takens:** `SingleTakensEmbedding( $d = 6, \tau = 3$ )` produce una matriz de 21×6 puntos.
2. **Persistencia Vietoris-Rips:** Se calculan diagramas de persistencia para H_0 y H_1 (en TDA v2 también H_2).
3. **Extracción de características:**
 - Entropía de persistencia (PE): 2 escalares (H_0 , H_1)
 - Amplitud: 2 escalares (H_0 , H_1)
 - Máxima persistencia H_1 : 1 escalar
 - Curvas de Betti (10 bins $\times$ 2 dimensiones): 20 escalares
 - Embedding aplanado (TDA v1): $21 \times 6 = 126$ escalares

El vector resultante tiene 152 componentes en TDA v1 (incluyendo el precio actual) y 157 en TDA v2 (que agrega distancias Wasserstein entre ventanas consecutivas, H_2 , y conteo de puntos H_1 sobre el percentil 75). Los vectores se apilan en una matriz F de

forma $(n_{\text{ventanas}}, N_{\text{features}})$ y se normalizan con **StandardScaler** ajustado únicamente en el conjunto de entrenamiento.

Una secuencia LSTM de entrada se construye como $X[i] = F[i : i + L]$ ($L = 12$ pasos) y el objetivo $y[i]$ es el precio del siguiente mes. Esto genera 168 secuencias a partir de las 180 ventanas disponibles ($n_{\text{total}} - W + 1 = 215 - 35 = 180$).

2.3 | Modelos comparados

La Tabla 5 describe todos los modelos evaluados, organizados por si incluyen o no características TDA.

Cuadro 5. Modelos evaluados con y sin TDA.

Modelo	TDA	Características de entrada
RF sin TDA	No	Precios históricos (rezagos)
SARIMA(1, 0, 1)(1, 0, 1) ₁₂	No	Serie de precios completa
LSTM puro	No	Secuencias de precios, (12, 1)
LSTM + Exógenas sin TDA	No	Precio + 8 variables macroeconómicas, (12, 9)
RF + TDA	Sí	26 características TDA (ventana $W = 18$)
SARIMA + TDA	Sí	SARIMA con regresores TDA externos
LSTM + TDA v1	Sí	152 características topológicas, (12, 152)
LSTM + TDA v2 sin exog	Sí	157 características TDA v2, (12, 157)
LSTM + TDA v1 + Calendario	Sí	TDA v1 + mes sin/cos, (12, 154)
LSTM + TDA v1 + Cal + Lag	Sí	TDA v1 + cal + lag-1 + lag-12, (12, 156)
LSTM + TDA v2 + Exog + Atención	Sí	TDA v2 + 8 exógenas + MultiHeadAttention
LightGBM + TDA v2 + Exog	Sí	1,980 características aplanadas
LSTM + EP Loss + Multi-Task	Sí	TDA v2, pérdida EP, cabeza clasificadora

2.3.1 Random Forest (RF)

El RF usa $n_{\text{estimators}} = 100$ y semilla aleatoria fija. Sin TDA, la entrada son los precios de los últimos 12 meses aplanados. Con TDA, se añaden las 26 características topológicas por paso temporal (312 entradas totales al aplanar el tensor 12×26).

2.3.2 SARIMA

Se ajustó un modelo SARIMA con orden $(p, d, q)(P, D, Q)_s = (1, 0, 1)(1, 0, 1)_{12}$, capturando la componente estacional anual. Con TDA, las características topológicas se incorporan como regresores exógenos en la parte no estacional del modelo.

2.3.3 LSTM

La arquitectura base es:

$$\text{Input} \rightarrow \text{LSTM}(64, \text{dropout} = 0.2) \rightarrow \text{LSTM}(32) \rightarrow \text{Dense}(16) \rightarrow \text{Dense}(1) \quad (2)$$

El modelo se entrena con pérdida MAE, optimizador Adam ($\eta = 10^{-3}$), *early stopping* con paciencia de 20 épocas sobre la pérdida de validación, y restauración de los mejores pesos. El número máximo de épocas es 200-400 según la variante.

La variante **LSTM + TDA v2 + Exog + Atención** añade una capa **MultiHeadAttention** (4 cabezas, $d_k = 16$) y **LayerNormalization** entre las dos capas LSTM, e incorpora 8 variables macroeconómicas como canales adicionales de entrada: S&P 500, IPC general, tasa de fondos federales, índice USD amplio, PPI frutas frescas, PPI vegetales, petróleo WTI y PPI agropecuario.

2.3.4 Enhanced Peak Loss + Multi-Task (Sesión 9)

Para mejorar la predicción de extremos locales, se diseñó una función de pérdida combinada:

$$\mathcal{L}(\alpha, \beta) = \underbrace{\mathbb{E}[(1 + \alpha \cdot \mathbf{1}_{\text{peak}}) \cdot |p_{\text{true}} - p_{\text{pred}}|]}_{\text{EP-MAE}} + \beta \cdot \underbrace{\mathbb{E}[\text{BCE}(\text{peak}_{\text{true}}, \text{peak}_{\text{pred}})]}_{\text{clasificación}} \quad (3)$$

donde BCE es la entropía cruzada binaria y $\mathbf{1}_{\text{peak}}$ indica si el mes objetivo es un extremo local (detectado con `argrelextrema(order = 3)`). Se realizó una búsqueda en cuadrícula sobre $\alpha \in \{2, 3, 5, 8\}$ y $\beta \in \{0.1, 0.3, 0.5\}$.

2.3.5 Características de Calendario y Lag (Sesión 10)

Se exploraron dos variantes de enriquecimiento sobre el LSTM + TDA v1:

- **Modelo A (+Calendario):** Se añaden $\sin(2\pi m/12)$ y $\cos(2\pi m/12)$, donde m es el mes objetivo, codificando cíclicamente la estacionalidad anual.
- **Modelo B (+Cal+Lag):** Además del calendario, se añaden lag-1 (p_{t-1}) y lag-12 (p_{t-12}) normalizados, para corregir el sesgo de desplazamiento observado en las predicciones.

2.4 | Validación

Se emplearon dos esquemas de división cronológica (sin mezcla aleatoria) dependiendo del tipo de modelo:

2.4.1 División para RF y SARIMA

- **Entrenamiento:** Junio 2008 – Diciembre 2024 (199 meses)
- **Prueba:** Enero 2025 – Abril 2026 (16 meses)

2.4.2 División para LSTM (todas las variantes)

Las 168 secuencias disponibles se partitionaron cronológicamente en 70/15/15:

- **Entrenamiento:** 117 secuencias ($\approx 70\%$)
- **Validación:** 25 secuencias ($\approx 15\%$) — usada para *early stopping*
- **Prueba:** 26 secuencias ($\approx 15\%$) — usada solo para reporte final

La normalización se aplicó con `StandardScaler` ajustado exclusivamente sobre el conjunto de entrenamiento y aplicado (sin reajuste) a validación y prueba, garantizando que no haya fuga de información del futuro.

Las métricas de evaluación son:

$$\text{MAE} = \frac{1}{n} \sum_{t=1}^n |p_t - \hat{p}_t|, \quad \text{RMSE} = \sqrt{\frac{1}{n} \sum_{t=1}^n (p_t - \hat{p}_t)^2}, \quad R^2 = 1 - \frac{\sum (p_t - \hat{p}_t)^2}{\sum (p_t - \bar{p})^2} \quad (4)$$

donde p_t es el precio real y $\hat{p}_t$ la predicción, ambas en escala original (índice PPI).

3 | Resultados

3.1 | Comparación global de métricas

La Tabla 6 presenta los resultados de los modelos clásicos (RF y SARIMA) evaluados sobre el periodo enero 2025 – abril 2026. La Tabla 7 resume los modelos LSTM evaluados sobre el conjunto de prueba de 26 meses.

Cuadro 6. Métricas en el conjunto de prueba — modelos RF y SARIMA (enero 2025 – abril 2026, $n = 16$).

Modelo	TDA	MAE	RMSE	R^2
RF sin TDA	No	41.19	52.10	−0,131
RF + TDA	Sí	41.09	52.04	−0,128
SARIMA(1, 0, 1)(1, 0, 1) ₁₂	No	29.42	36.11	+0,457
SARIMA + TDA	Sí	30.57	36.42	+0,447

Cuadro 7. Métricas en el conjunto de prueba — modelos LSTM (26 meses).

Modelo	TDA	MAE	RMSE	R^2
RF sin TDA (línea base)	No	38.71	48.96	+0,265
LSTM puro	No	33.44	44.84	+0,383
LSTM + Exógenas sin TDA	No	45.69	56.49	+0,021
LSTM + TDA v2 sin exog (Modelo 5)	Sí	33.00	43.03	+0,432
LSTM + TDA v1 (Sesión 6)	Sí	29.49	37.50	+0,569
LSTM + TDA v1 + Calendario (Sesión 10 A)	Sí	30.31	39.16	+0,530
LSTM + TDA v1 + Cal + Lag (Sesión 10 B)	Sí	30.10	38.09	+0,555
LSTM + EP Loss + Multi-Task (Sesión 9)	Sí	33.52	43.17	+0,428
LightGBM + TDA v2 + Exog	Sí	39.01	49.64	+0,244
LSTM + TDA v2 + Exog + Atención	Sí	29.11	38.63	+0,542

El **modelo ganador** es **LSTM + TDA v2 + Exógenas + Atención** con MAE = 29,11, una reducción del 24.8 % respecto al RF sin TDA (MAE = 38,71) y del 12.9 % respecto al LSTM puro (MAE = 33,44) en la misma división de prueba.

3.2 | Predicciones futuras

Los modelos fueron entrenados con toda la información disponible hasta abril de 2026, incluyendo el conjunto de validación. Las predicciones futuras (mayo–diciembre 2026) se generan de forma autoregresiva: el precio predicho en cada paso se retroalimenta como entrada del siguiente. La Tabla 8 reporta las predicciones del mejor modelo y del SARIMA para el segundo semestre de 2026. Dado que los modelos dependen de variables exógenas (LSTM + Atención) y de datos no disponibles al momento de este reporte, los valores se presentan como ilustrativos basados en la extrapolación de las características TDA sobre la última ventana disponible.

Cuadro 8. Predicciones comparativas — mes a mes (mayo–diciembre 2026). Valores ilustrativos basados en extrapolación autoregresiva del SARIMA y la tendencia TDA del último trimestre.

Mes	SARIMA(1, 0, 1)(1, 0, 1) ₁₂	Tendencia TDA
Mayo 2026	~ 130–145	Recuperación hacia media histórica
Junio 2026	~ 120–135	Valle estacional (transición cosecha)
Julio 2026	~ 110–125	Mínimo estacional estimado
Agosto 2026	~ 120–140	Inicio de recuperación
Septiembre 2026	~ 140–160	Aceleración pre-cosecha
Octubre 2026	~ 170–200	Pico tardío estimado
Noviembre 2026	~ 200–230	Pico máximo estimado
Diciembre 2026	~ 180–220	Inicio de descenso post-cosecha

3.3 | Visualizaciones

3.3.1 Comparación de predicciones en validación

La Figura 2 ilustra esquemáticamente el comportamiento de los modelos en el periodo de prueba. El LSTM + TDA v1 y el LSTM + TDA v2 + Atención siguen con mayor fidelidad los picos y valles de la serie real, mientras que el RF y el LSTM puro tienden a suavizar los extremos o a desplazar las predicciones un paso hacia adelante.




Figura 2. Pronóstico vs. valores reales en el conjunto de prueba (estudio de ablación, Sesión 8). Línea negra: precio real. Las demás líneas muestran las predicciones de los modelos LSTM puro, LSTM+TDA v2 sin exógenas, LSTM+Exógenas sin TDA y LSTM+TDA v2+Exog+Atención.

3.3.2 Comparación gráfica de métricas

La Figura 3 ilustra el MAE de todos los modelos en el conjunto de prueba, ordenados de mayor a menor error.




Figura 3. MAE en el conjunto de prueba para todos los modelos evaluados, ordenados de mayor a menor error. Las barras verdes corresponden a modelos que incorporan características TDA; las barras azules a modelos sin TDA. La línea roja punteada marca el MAE del modelo ganador (LSTM + TDA v2 + Exog + Atención, MAE = 29.11).

3.3.3 Diagramas de persistencia por subperiodo

Los diagramas de persistencia (Figura 4) muestran la estructura topológica de la serie en cada subperiodo. En H_1 , el subperiodo 2008-2012 presenta puntos alejados de la diagonal (alta persistencia = 130,1), indicando ciclos de gran amplitud y duración. El subperiodo 2020-2026 presenta puntos agrupados cerca de la diagonal (baja persistencia = 7,99), reflejando la ruptura estructural causada por la pandemia.




Figura 4. Diagramas de persistencia de Vietoris-Rips por subperiodo histórico ($d = 12$, $\tau = 3$). Los puntos en H_0 representan componentes conexas; los puntos en H_1 representan ciclos. La distancia a la diagonal indica la persistencia de cada característica topológica. El subperiodo 2008-2012 presenta la mayor dispersión en H_1 (persistencia máx. = 130.1).

3.3.4 Métricas comparativas (MAE , $RMSE$, R^2)

La Figura 5 presenta las tres métricas de evaluación para los modelos representativos de cada familia, mostrando la ganancia consistente de los modelos con TDA en MAE y $RMSE$, y el salto más pronunciado en R^2 (de valores negativos para RF sin TDA a 0.57 para LSTM + TDA v1).




Figura 5. Comparación de MAE, RMSE y R^2 para los modelos más representativos. Barras verdes: modelos con TDA. Barras azules: modelos sin TDA. En R^2 , valores negativos indican que el modelo es peor que predecir la media de la serie.

3.3.5 Calendario y lag — Sesión 10

La Figura 6 muestra el impacto de agregar características de calendario y rezago sobre el LSTM + TDA v1. El Modelo B (calendario + lag) logra seguir mejor los puntos de inflexión estacionales respecto a la línea base.




Figura 6. Pronóstico en el conjunto de prueba para los tres modelos de Sesión 10: Baseline TDA v1 (152 características), Modelo A (+calendario, 154) y Modelo B (+calendario+lag, 156). El Modelo B alcanza MAE = 30.10, mejora del 5.7 % sobre la línea base (31.93).

3.3.6 Grid search EP Loss (Sesión 9)

La búsqueda en cuadrícula de los hiperparámetros α y β de la función EP Loss reveló que la combinación óptima fue $(\alpha^*, \beta^*) = (2, 0, 1)$, con un MAE de validación de 23.96 puntos. La Figura 7 muestra el mapa de calor del MAE de validación por combinación.




Figura 7. Mapa de calor del MAE de validación en el grid search de EP Loss ($\alpha \in \{2, 3, 5, 8\}$, $\beta \in \{0.1, 0.3, 0.5\}$, 12 combinaciones). Colores más fríos (verdes) indican menor error. El mínimo se alcanzó en $\alpha = 2$, $\beta = 0.1$ con $\text{MAE}_{\text{val}} = 23.96$.

4 | Discusión

4.1 | ¿Aportan las características TDA valor predictivo?

La respuesta es condicional a la clase de modelo. En los modelos de árbol (RF), la ganancia de TDA fue marginal (+0.25 % en el conjunto de prueba con validación Jan-2025 a Abr-2026), lo que sugiere que el bosque aleatorio no aprovecha eficientemente la geometría topológica del espacio de características. En contraste, el LSTM + TDA v1 redujo el MAE en un 23.8 % respecto al RF sin TDA ($38.71 \rightarrow 29.49$), y el LSTM + TDA v2 + Exógenas + Atención alcanzó el menor MAE global (29.11), lo que confirma que las redes LSTM sí explotan la dependencia temporal secuencial de los descriptores topológicos.

La razón intuitiva es que el TDA codifica la *forma* de la serie en una ventana de 36 meses —cuántos ciclos existen, qué tan persistentes son, cuál es la entropía topológica— y el LSTM aprende a relacionar la *evolución* de esa forma con los precios futuros. Un árbol de decisión trata cada feature de forma independiente y no explota la dependencia secuencial del tensor (12, 152).

4.2 | Rendimiento comparativo por clase de modelo

Entre los modelos sin TDA, el SARIMA supera al RF (MAE 29.42 vs. 41.19) porque captura explícitamente la estacionalidad mensual mediante el componente $(P, D, Q)_s = (1, 0, 1)_{12}$. El LSTM puro (MAE 33.44) se posiciona entre ambos: aprende patrones secuenciales pero sin información topológica ni estacionalidad explícita.

Un resultado contraintuitivo es que SARIMA + TDA tuvo peor desempeño que SARIMA puro (−3.88 % de mejora), mientras que LSTM + TDA mejoró sustancialmente

sobre LSTM puro. Esto indica que el TDA como regresor exógeno en SARIMA introduce ruido en lugar de señal: las características topológicas son altamente correlacionadas y no se benefician del supuesto de linealidad del modelo SARIMA.

El LSTM + Exógenas *sin* TDA (MAE 45.69) fue el peor modelo del estudio, incluso por debajo del RF sin TDA. Las ocho variables macroeconómicas (S&P 500, CPI, Fed Funds, etc.) no alinearon bien con la dinámica de los precios de berries en el corto periodo de datos disponible ($n = 180$ ventanas), y su alta dimensionalidad con pocas muestras provocó sobreajuste severo. Al combinar estas variables exógenas con las características TDA v2 y el mecanismo de atención, el modelo pudo aprender a ponderar selectivamente las fuentes de información, reduciendo el MAE a 29.11.

4.3 | Técnicas avanzadas: EP Loss y características adicionales

La función de pérdida EP Loss (Sesión 9) con la configuración óptima ($\alpha = 2, \beta = 0,1$) produjo un MAE de prueba de 33.52, superior al LSTM + TDA v1 simple (29.49). La causa probable es que penalizar los extremos con solo $\alpha = 2$ (el mejor hiperparámetro) introduce una perturbación moderada en la pérdida que no compensó la reducción de complejidad respecto al LSTM + TDA v2. Con tan pocos extremos locales en el conjunto de entrenamiento (≈ 32 de 168 muestras, 19 %), la cabeza clasificadora no recibió suficiente señal supervisora para mejorar el pronóstico global.

Las características de calendario y lag (Sesión 10) sí aportaron mejoras consistentes sobre la línea base: el Modelo B (TDA v1 + calendario + lag-1 + lag-12) redujo el MAE de 31.93 a 30.10 ($-5,7\%$). El lag-1 explícito mitiga el sesgo de desplazamiento típico de los LSTM —en el que la predicción imita el valor previo— y el calendario cicla la estacionalidad mensual sin necesidad de que el modelo la infiera implícitamente.

4.4 | Limitaciones

1. **Tamaño de muestra:** Con 117 muestras de entrenamiento (versiones LSTM), el ajuste de redes profundas está limitado. Los resultados podrían mejorar con datos mensuales de mayor historia o frecuencia semanal.
2. **Costo computacional del TDA:** La extracción de características topológicas sobre la ventana deslizante toma del orden de varios minutos por corrida. El caché de F como archivo `.npy` resuelve esto en producción, pero complica el reentrenamiento ante nuevos datos.
3. **Variables exógenas desalineadas:** Los datos macroeconómicos descargados via `fredapi` y `yfinance` presentaron algunos meses con datos faltantes que se imputaron por propagación hacia adelante (≤ 2 meses), introduciendo cierta imprecisión en las features exógenas.
4. **Estabilidad de los resultados LSTM:** Las métricas de los modelos LSTM pueden variar ligeramente entre ejecuciones por la inicialización aleatoria, aunque el uso de semillas fijas (`tf.random.set_seed(42)`) reduce esta variabilidad.
5. **Predicciones futuras:** La extrapolación autoregresiva más allá del conjunto de prueba acumula error de forma cuadrática; los valores para 2026 son indicativos y

no deben interpretarse como pronósticos de alta confianza.

5 | Conclusiones

5.1 | Resumen de hallazgos

Este estudio analizó el Índice de Precios al Productor de Berries (WPUSI01102B) desde la perspectiva del Análisis Topológico de Datos, construyendo y comparando 11 variantes de modelos de pronóstico. Los principales hallazgos son:

1. **La estructura topológica de la serie varía significativamente entre subperiodos.** La persistencia máxima en H_1 cayó de 130.1 (2008-2012) a 22.4 (2013-2019) y 8.0 (2020-2026), reflejando la ruptura de los ciclos estacionales durante la pandemia.
2. **Las características TDA mejoran el pronóstico cuando se combinan con LSTM.** El LSTM + TDA v1 redujo el MAE en 23.8 % respecto al RF sin TDA. El modelo más sofisticado (LSTM + TDA v2 + Exógenas + Atención) alcanzó MAE = 29,11, el mejor resultado del estudio.
3. **TDA no aporta ventaja en modelos lineales (SARIMA) ni en árboles (RF).** SARIMA + TDA fue ligeramente peor que SARIMA puro; RF + TDA mejoró solo 0,25 %.
4. **El SARIMA es competitivo sin TDA.** Con MAE = 29,42 (comparable al LSTM + TDA v1), el SARIMA es una línea base difícil de superar gracias a su modelado explícito de la estacionalidad de 12 meses.
5. **El calendario y los lags explícitos mejoran el LSTM + TDA.** Añadir mes sin/cos y los rezagos 1 y 12 redujo el MAE de 31.93 a 30.10 (−5,7 %).

5.2 | Trabajo futuro

Las siguientes líneas de trabajo podrían mejorar los resultados obtenidos:

1. **Datos de mayor frecuencia:** Incorporar datos semanales del USDA o precios spot de mercados mayoristas para aumentar el tamaño de entrenamiento.
2. **Transformers para series de tiempo:** Reemplazar el LSTM por un Transformer temporal (e.g., Temporal Fusion Transformer) que incorpore mecanismos de atención sobre las características TDA directamente.
3. **Parámetros TDA óptimos adaptivos:** En lugar de fijar $d = 6$ y $\tau = 3$ globalmente, optimizar estos parámetros por ventana deslizante usando validación cruzada temporal, permitiendo que la representación topológica se adapte al régimen corriente.
4. **Detección de cambios de régimen:** Usar la distancia de Wasserstein entre diagramas consecutivos como indicador de alerta temprana de rupturas estructurales en los precios.

5. **Intervalos de predicción:** Implementar pronóstico probabilístico (e.g., cuantil LSTM o conformal prediction) para cuantificar la incertidumbre de los pronósticos, especialmente importante en mercados agrícolas de alta volatilidad.
6. **Generalización a otras commodities agrícolas:** Replicar el pipeline TDA sobre otras series del PPI agrícola (vegetales, frutas tropicales, granos) para validar si la ganancia de TDA es específica de las berries o generalizable.

El código fuente completo, los notebooks de análisis y los datos de este proyecto están disponibles públicamente en:

https://github.com/JosueT1212/Berries_Stock_Forecasting

Referencias

Bauer, U. (2021).

Ripser: efficient computation of Vietoris-Rips persistence barcodes. *Journal of Applied and Computational Topology*, 5(3), 391-423.

Carlsson, G. (2009).

Topology and data. *Bulletin of the American Mathematical Society*, 46(2), 255-308.

Chazal, F., & Michel, B. (2021).

An introduction to topological data analysis: fundamental and practical aspects for data scientists. *Frontiers in Artificial Intelligence*, 4, 667963.

Federal Reserve Bank of St. Louis. (2026).

FRED Producer Price Index for Berries (WPUSI01102B). <https://fred.stlouisfed.org/series/WPUSI01102B>

Gidea, M., & Katz, Y. (2018).

Topological data analysis of financial time series: Landscapes of crashes. *Physica A: Statistical Mechanics and its Applications*, 491, 820-834.

Giotto-TDA team. (2023).

giotto-tda: A topological machine learning toolbox in Python. <https://giotto-ai.github.io/gtda-docs/>

Hochreiter, S., & Schmidhuber, J. (1997).

Long short-term memory. *Neural Computation*, 9(8), 1735-1780.

Otter, N., Porter, M. A., Tillmann, U., Grindrod, P., & Harrington, H. A. (2017).

A roadmap for the computation of persistent homology. *EPJ Data Science*, 6(1), 17.

Pedregosa, F., et al. (2011).

Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

Takens, F. (1981).

Detecting strange attractors in turbulence. En D. Rand & L.-S. Young (Eds.), *Dynamical Systems and Turbulence* (pp. 366-381). Springer.

Tralie, C., Saul, N., & Bar-On, R. (2018).

Ripser.py: A lean persistent homology library for Python. *Journal of Open Source Software*, 3(29), 925.

Zomorodian, A., & Carlsson, G. (2005).

Computing persistent homology. *Discrete & Computational Geometry*, 33(2), 249-274.